

Comparações estatísticas de classificadores em vários conjuntos de dados

Janez Demsar^{*}

JANEZ.DEMSAR@FRI.UNI-LJ.SI

Faculdade de Ciência da Computação e Informação

Trzajška 25

Liubliana, Eslovênia

Editor: Dale Schuurmans

Resumo

Embora os métodos para comparar dois algoritmos de aprendizado em um único conjunto de dados já tenham sido examinados há algum tempo, a questão dos testes estatísticos para comparações de mais algoritmos em vários conjuntos de dados, o que é ainda mais essencial para estudos típicos de aprendizado de máquina, tem sido totalmente ignorada. Este artigo revisa a prática atual e, em seguida, examina teórica e empiricamente diversos testes adequados. Com base nisso, recomendamos um conjunto de testes não paramétricos simples, porém seguros e robustos, para comparações estatísticas de classificadores: o teste de postos sinalizados de Wilcoxon para comparação de dois classificadores e o teste de Friedman com os testes post-hoc correspondentes para comparação de mais classificadores em múltiplos conjuntos de dados. Os resultados deste último também podem ser apresentados de forma organizada com os diagramas de CD (diferença crítica) recentemente introduzidos.

Palavras-chave: estudos comparativos, métodos estatísticos, teste de postos sinalizados de Wilcoxon, teste de Friedman, testes de comparações múltiplas

1. Introdução

Nos últimos anos, a comunidade de aprendizado de máquina tem se conscientizado cada vez mais da necessidade de validação estatística dos resultados publicados. Isso pode ser atribuído à maturidade da área, ao crescente número de aplicações no mundo real e à disponibilidade de estruturas abertas de aprendizado de máquina que facilitam o desenvolvimento de novos algoritmos ou a modificação dos existentes, bem como a comparação entre eles.

Em um artigo típico sobre aprendizado de máquina, um novo algoritmo de aprendizado de máquina, parte dele ou alguma nova etapa de pré ou pós-processamento é proposto, e a hipótese implícita é de que tal aprimoramento resulta em um desempenho superior ao(s) algoritmo(s) existente(s). Alternativamente, várias soluções para um problema são propostas e o objetivo é diferenciar as bem-sucedidas das que falharam. Vários conjuntos de dados de teste são selecionados para teste, os algoritmos são executados e a qualidade dos modelos resultantes é avaliada usando uma medida apropriada, mais comumente a precisão da classificação. A etapa restante, e o tópico deste artigo, é verificar estatisticamente a hipótese de desempenho aprimorado.

A seção a seguir explora o trabalho teórico relacionado e a prática existente. Vários pesquisadores abordaram o problema de comparar dois classificadores em um único conjunto de dados e propuseram diversas soluções. Sua mensagem foi aceita pela comunidade, e os testes t pareados excessivamente confiáveis sobre dobras de validação cruzada estão dando lugar ao teste de McNemar e à validação cruzada **5×2**.

Por outro lado, a comparação de vários classificadores em vários conjuntos de dados — uma situação que é ainda mais comum, especialmente quando o desempenho geral e não o desempenho em determinados conjuntos específicos

O problema é testado — ainda é teoricamente inexplorado e deixado para vários procedimentos *ad hoc* que carecem de base estatística ou utilizam métodos estatísticos de maneiras inadequadas. Para ver o que é usado na prática, estudamos os anais recentes (1999-2003) da Conferência Internacional sobre Aprendizado de Máquina. Observamos que muitos artigos excelentes e inovadores sobre aprendizado de máquina terminam tirando conclusões de uma matriz de, por exemplo, testes de McNemar comparando todos os pares de classificadores, como se os testes para comparações múltiplas, como ANOVA e teste de Friedman, ainda não tivessem sido inventados.

O núcleo do artigo é o estudo dos testes estatísticos que poderiam ser (ou já são) usados para comparar dois ou mais classificadores em múltiplos conjuntos de dados. Formalmente, assumamos que testamos k algoritmos de aprendizagem em N conjuntos de dados. Seja c_{ij} a pontuação de desempenho do j -ésimo algoritmo no i -ésimo conjunto de dados. A tarefa é decidir se, com base nos valores de c_{ij} , os algoritmos são estatisticamente significativamente diferentes e, no caso de mais de dois algoritmos, quais são os algoritmos particulares que diferem em desempenho. Não registraremos a variância dessas pontuações, $\hat{c}_{ij}$ assumimos que os resultados medidos são "confiáveis"; para esse fim, exigimos que experimentos suficientes tenham sido feitos em cada conjunto de dados, mas só irá e, preferencialmente, que todos os algoritmos tenham sido avaliados usando as mesmas amostras aleatórias. Não fazemos outras suposições sobre o esquema de amostragem.

Na Seção 3, observaremos os pressupostos teóricos por trás de cada teste à luz do nosso problema. Embora alguns dos testes sejam bastante comuns na literatura sobre aprendizado de máquina, muitos pesquisadores parecem desconhecer o que os testes realmente medem e para quais circunstâncias são adequados. Também mostraremos como apresentar os resultados de comparações múltiplas com gráficos organizados e de fácil compreensão. Na Seção 4, forneceremos alguns insights empíricos sobre as propriedades dos testes.

2. Trabalhos anteriores

A avaliação estatística de resultados experimentais tem sido considerada uma parte essencial da validação de novos métodos de aprendizado de máquina há algum tempo. No entanto, os testes utilizados têm sido bastante ingênuos e não verificados. Embora os procedimentos para comparação de um par de classificadores em um único problema tenham sido propostos há quase uma década, estudos comparativos com mais classificadores e/ou mais conjuntos de dados ainda empregam soluções parciais e insatisfatórias.

2.1 Trabalho Teórico Relacionado

Um dos artigos mais citados nessa área é o de Dietterich (1998). Após descrever a taxonomia de questões estatísticas em aprendizado de máquina, ele se concentra na questão de decidir qual dos dois algoritmos em estudo produzirá classificadores mais precisos quando testado em um determinado conjunto de dados. Ele examina cinco testes estatísticos e conclui a análise recomendando o recém-criado teste $t_{5 \times 2cv}$, que supera o problema da variância subestimada e o consequente erro Tipo I elevado do teste t pareado mais tradicional sobre as dobras da validação cruzada usual de k dobras.

Para os casos em que executar o algoritmo várias vezes não é apropriado, Dietterich considera o teste de McNemar sobre a matriz de classificação incorreta tão poderoso quanto o teste $t_{5 \times 2cv}$. Ele alerta contra testes t após amostragem aleatória repetitiva e também desencoraja o uso de testes t após validação cruzada. O teste $t_{5 \times 2cv}$ foi aprimorado por Alpaydm (1999), que construiu um teste $F_{5 \times 2cv}$ mais robusto, com menor erro tipo I e maior poder.

Bouckaert (2003) argumenta que os graus de liberdade teóricos são incorretos devido às dependências entre os experimentos e que, em vez disso, devem ser utilizados valores encontrados empiricamente, enquanto Nadeau e Bengio (2000) propõem o teste t reamostrado corrigido, que ajusta a variância com base nas sobreposições entre subconjuntos de exemplos. Bouckaert e Frank (Bouckaert e Frank, 2004; Bouckaert, 2004) também investigaram a replicabilidade de experimentos de aprendizado de máquina, consideraram o teste t $5 \times 2cv$ insatisfatório e optaram pelo teste t reamostrado corrigido. Para um trabalho mais geral sobre o problema de estimativa da variância da validação cruzada k-fold, consulte o trabalho de Bengio e Grandvalet (2004).

Nenhum dos estudos acima aborda a avaliação do desempenho de múltiplos classificadores e nenhum estuda a aplicabilidade das estatísticas quando os classificadores são testados em múltiplos conjuntos de dados. Para o primeiro caso, Salzberg (1997) menciona a ANOVA como uma das soluções possíveis, mas em seguida descreve o teste binomial com a correção de Bonferroni para comparações múltiplas. Como o próprio Salzberg observa, o teste binomial não tem o poder dos melhores testes não paramétricos e a correção de Bonferroni é excessivamente radical. Vazquez et al. (2001) e Pizarro et al. (2002), por exemplo, utilizam a ANOVA e o teste de Friedman para comparação de múltiplos modelos (em particular, redes neurais) em um único conjunto de dados.

Por fim, para a comparação de classificadores em múltiplos conjuntos de dados, Hull (1994) foi, até onde sabemos, o primeiro a utilizar testes não paramétricos para comparar classificadores na recuperação de informação e na avaliação da relevância de documentos (ver também Schutze et al., 1995). Brazdil e Soares (2000) utilizaram classificações médias para comparar algoritmos de classificação. Visando um objetivo diferente, o de escolher o algoritmo ideal, eles não testam estatisticamente a significância das diferenças entre eles.

2.2 Testes na Prática: Análise de Artigos ICML

Analizamos os artigos dos anais de cinco Conferências Internacionais recentes sobre Aprendizado de Máquina (1999-2003). Concentramo-nos nos artigos que comparam pelo menos dois classificadores medindo sua precisão de classificação, erro quadrático médio, área sob a curva (AUC) (Beck e Schultz, 1986), precisão/recall ou alguma outra pontuação de desempenho do modelo.

Os métodos e medidas de amostragem utilizados para avaliar o desempenho dos classificadores não são diretamente relevantes para este estudo. É surpreendente, porém, que a precisão da classificação geralmente ainda seja a única medida utilizada, apesar das vozes da comunidade médica (Beck e Schultz, 1986; Bellazzi e Zupan, 1998) e da comunidade de aprendizado de máquina (Provost et al., 1998; Langley, 2000) insistindo que outras medidas, como a AUC, também sejam utilizadas. A única competição real com a precisão da classificação são as medidas utilizadas na área de recuperação de documentos. Este também é o único campo em que a abundância de dados permite o uso de conjuntos de dados de teste separados em vez de validação cruzada ou amostragem aleatória.

De maior interesse para o nosso artigo são os métodos de análise de diferenças entre os algoritmos. Os artigos estudados publicaram os resultados de dois ou mais classificadores em múltiplos conjuntos de dados, geralmente em formato tabular. Não registramos quantos deles incluem declarações (informais) sobre o desempenho geral dos classificadores. No entanto, de um quarto a até metade dos artigos incluem algum procedimento estatístico para determinar o método ótimo ou para comparar os desempenhos entre si.

A maneira mais direta de comparar classificadores é calcular a média de todos os conjuntos de dados; esse cálculo de média parece ingênuo e raramente é utilizado. Os testes t pareados são praticamente o único método usado para avaliar a significância estatística das diferenças. Eles se enquadram em três categorias: apenas dois métodos

DEMSAR

	1999	2000	2001	2002	2003
Número total de artigos	54	152	80	87	118
Artigos relevantes para nosso estudo	19	45	25	31	54
Método de amostragem [%]					
validação cruzada, reamostragem	22	49	44	42	56
aleatória de leave-one-	11	29	44	32	54
out, subconjunto separado	5	11	0	13	9
Função de pontuação [%]					
precisão de classificação	74	67	84	84	70
precisão de classificação - <i>exclusivamente</i>	68	60	80	58	67
recall, precisão. . .	21	18	16	25	19
ROC, AUC	0	4	4	13	9
desvios, intervalos de confiança	32	42	48	42	19
Comparação geral das médias dos classificadores	53	44	44	26	45
[%] sobre os conjuntos de dados	0	4	6	0	10
teste t para comparar dois algoritmos teste	16	11	4	6	7
t em pares um vs. outros teste t em	5	11	16	3	7
pares cada vs. cada	16	13	4	6	4
contagens de vitórias/empates/	5	4	0		9
derrotas contagens de vitórias/empates/derrotas <i>significativas</i>	16	4	8	6	16

Tabela 1: Uma visão geral dos artigos aceitos na Conferência Internacional sobre Aprendizado de Máquina nos anos de 1999 a 2003. As percentagens relatadas (terceira linha e abaixo) aplicam-se ao número de artigos relevantes para nosso estudo.

são comparados, um método (um novo método ou o método base) é comparado aos outros, ou todos métodos são comparados entre si. Apesar dos avisos repetitivos contra múltiplas hipóteses Em testes, a correção de Bonferroni é usada apenas em alguns artigos do ICML anualmente. Uma abordagem não paramétrica comum é contar o número de vezes que um algoritmo tem desempenho melhor, pior ou igual. para os outros; a contagem às vezes é feita em pares, resultando em uma matriz de contagem de vitórias/empates/derrotas, e a A alternativa é contar o número de conjuntos de dados nos quais o algoritmo superou todos os outros. Alguns autores preferem contabilizar apenas as diferenças que foram estatisticamente significativas; para verificar isso, eles usam várias técnicas para comparação de dois algoritmos que foram revisados acima.

Estes números devem ser analisados com alguma cautela. Alguns artigos não descrevem explicitamente a métodos de amostragem e teste utilizados. Além disso, muitas vezes pode ser difícil decidir se um determinado procedimento de amostragem, teste ou medida de qualidade é equivalente ao geral ou não.

3. Estatísticas e Testes para Comparação de Classificadores

A visão geral mostra que não existe um procedimento estabelecido para comparar classificadores em vários conjuntos de dados. Vários pesquisadores adotam diferentes técnicas estatísticas e de senso comum para decidir se as diferenças entre os algoritmos são reais ou aleatórias. Nesta seção, examinaremos

vários testes estatísticos conhecidos e menos conhecidos, e estudar sua adequação ao nosso propósito do ponto de vista do que eles realmente medem e de sua segurança em relação às suposições que fazem sobre os dados.

Como ponto de partida, dois ou mais algoritmos de aprendizagem foram executados em um conjunto adequado de dados e avaliados usando precisão de classificação, AUC ou alguma outra medida (ver Tabelas 2 e 6 para um exemplo). Não registramos a variância desses resultados em múltiplas amostras e, portanto, não assumimos nada sobre o esquema de amostragem. O único requisito é que os resultados compilados forneçam estimativas confiáveis do desempenho dos algoritmos em cada conjunto de dados. Em configurações experimentais usuais, esses números provêm de validação cruzada ou de divisões aleatórias estratificadas repetidas em conjuntos de dados de treinamento e teste.

Existe uma diferença fundamental entre os testes usados para avaliar a diferença entre dois classificadores em um único conjunto de dados e as diferenças em múltiplos conjuntos de dados. Ao testar em um único conjunto de dados, geralmente calculamos o desempenho médio e sua variância ao longo de treinamentos repetitivos e testes em amostras aleatórias de exemplos. Como essas amostras geralmente são relacionadas, é necessário muito cuidado ao projetar os procedimentos estatísticos e testes que evitam problemas com estimativas tendenciosas de variância.

Em nossa tarefa, a reamostragem múltipla de cada conjunto de dados é usada apenas para avaliar a pontuação de desempenho e não sua variância. As fontes da variância são as diferenças de desempenho em conjuntos de dados (independentes) e não em amostras (geralmente dependentes), portanto, o erro Tipo 1 elevado não é um problema. Como a reamostragem múltipla não distorce a estimativa da pontuação, vários tipos de validação cruzada ou procedimentos de exclusão de um parâmetro podem ser usados sem qualquer risco.

Além disso, o problema dos testes estatísticos corretos para comparar classificadores em um único conjunto de dados não está relacionado à comparação em múltiplos conjuntos de dados, no sentido de que teríamos que resolver o primeiro problema para lidar com o segundo. Como a execução dos algoritmos em múltiplos conjuntos de dados naturalmente resulta em uma amostra de medições independentes, tais comparações são ainda mais simples do que comparações em um único conjunto de dados.

Devemos também enfatizar que o "tamanho da amostra" na seção seguinte se refere ao número de conjuntos de dados utilizados, não ao número de amostras de treinamento/teste extraídas de cada conjunto individual ou ao número de instâncias em cada conjunto. O tamanho da amostra pode, portanto, ser tão pequeno quanto cinco e geralmente fica bem abaixo de 30.

3.1 Comparações de dois classificadores

Na discussão dos testes para comparações de dois classificadores em múltiplos conjuntos de dados, faremos dois pontos. Alertaremos contra o amplamente utilizado teste t , por ser geralmente conceitualmente inadequado e estatisticamente inseguro. Como finalmente recomendaremos o teste de postos sinalizados de Wilcoxon (1945), ele será apresentado com mais detalhes. Outro teste, ainda mais raramente utilizado, é o teste do sinal, que é mais fraco que o teste de Wilcoxon, mas também tem seus méritos distintos. A outra mensagem será que as estatísticas descritas medem diferenças entre os classificadores sob diferentes aspectos, portanto, a seleção do teste deve se basear não apenas na adequação estatística, mas também no que pretendemos medir.

3.1.1 CÁLCULO DA MÉDIA SOBRE CONJUNTOS DE DADOS

Alguns autores de artigos sobre aprendizado de máquina calculam as precisões médias de classificação dos classificadores nos conjuntos de dados testados. Nas palavras de Webb (2000), "é discutível se as taxas de erro em diferentes domínios são comensuráveis e, portanto, se a média das taxas de erro entre domínios é muito significativa".

"ingful". Se os resultados em diferentes conjuntos de dados não forem comparáveis, suas médias não terão significado. Um caso diferente são os estudos em que os algoritmos são comparados em um conjunto de problemas relacionados, como bancos de dados médicos para uma determinada doença de diferentes instituições ou vários problemas de mineração de texto com propriedades semelhantes.

As médias também são suscetíveis a valores discrepantes. Elas permitem que o excelente desempenho do classificador em um conjunto de dados compense o desempenho geral ruim ou, inversamente, uma falha total em um domínio pode prevalecer sobre os resultados razoáveis na maioria dos outros. Pode haver situações em que tal comportamento seja desejável, embora, em geral, provavelmente preferamos classificadores que se comportem bem no maior número possível de problemas, o que torna a média de conjuntos de dados inadequada.

Dado que poucos artigos relatam tais médias, podemos presumir que a comunidade geralmente as considera insignificantes. Consequentemente, as médias também não são usadas (nem úteis) para inferência estatística com o teste z ou t .

3.1.2 TESTE T EMPARELHADO

Uma maneira comum de testar se a diferença entre os resultados de dois classificadores em vários conjuntos de dados não é aleatória é calcular um teste t pareado, que verifica se a diferença média no desempenho deles nos conjuntos de dados é significativamente diferente de zero.

Seja $c_1, c_2, \dots, c_N$ e $c'_1, c'_2, \dots, c'_N$ sejam as pontuações de desempenho de dois classificadores no i -ésimo de N conjuntos de dados e $d_i = c_i - c'_i$ seja a diferença $c_i - c'_i$. A estatística t é calculada como $d/\hat{\sigma}_d$ e é distribuída de acordo com

Distribuição de alunos com $N-1$ graus de liberdade.

Em nosso contexto, o teste t apresenta três fragilidades. A primeira é a comensurabilidade: o teste t só faz sentido quando as diferenças entre os conjuntos de dados são comensuráveis. Nessa perspectiva, usar o teste t pareado para comparar um par de classificadores faz tão pouco sentido quanto calcular as médias entre os conjuntos de dados. A diferença média d é igual à diferença entre as pontuações médias dos dois classificadores, $d = c - c'$.

A única distinção entre esta forma do teste t e a comparação das duas médias (como as discutidas acima) usando diretamente o teste t para amostras não relacionadas está no denominador: o teste t pareado diminui o erro padrão $\hat{\sigma}_d$ pela variância entre os conjuntos de dados (ou, em outras palavras, pela covariância entre os classificadores).

Webb (2000) aborda o problema da comensurabilidade calculando as médias geométricas que esta estatística representa de proporções relativas, $(c_i/c_{\max})^{1/N} / (c'_i/c'_{\max})^{1/N}$. Como isso é igual a $e^{(1/N) \ln(c_i/c_{\max}) - (1/N) \ln(c'_i/c'_{\max})}$, essencialmente

o mesmo que as médias ordinárias, exceto que compara logaritmos de pontuações. A utilidade dessa transformação é, portanto, bastante questionável. Quinlan (1996) calcula médias aritméticas de proporções relativas; devido a distribuições assimétricas, estas não podem ser usadas no teste t sem manipulação adicional.

Uma maneira mais simples de compensar a complexidade diferente dos problemas é dividir a diferença pela pontuação média, $d_i = (c_i - c'_i) / ((c_i + c'_i)/2)$. O segundo problema

com o teste t é que, a menos que o tamanho da amostra seja grande o suficiente (≥ 30 conjuntos de dados), o teste t pareado requer que as diferenças entre as duas variáveis aleatórias comparadas sejam distribuídas normalmente. A natureza dos nossos problemas não fornece nenhuma provisão para normalidade e o número de conjuntos de dados geralmente é muito menor que 30. Ironicamente, os testes de Kolmogorov-Smirnov e similares para testar a normalidade das distribuições têm pouco poder em amostras pequenas, ou seja, é improvável que detectem anormalidades e alertam contra o uso do teste t . Portanto, para usar o teste t , precisamos de distribuições normais porque temos amostras pequenas, mas as amostras pequenas também nos proíbem de verificar o formato da distribuição.

Classificação de diferença C4.5 C4.5+m	
adulto (amostra) 0,763 0,768 +0,005 3,5	
câncer de mama 0,599 0,591 -0,008 7	
câncer de mama wisconsin 0,954 0,971 +0,017 9	
cmc 0,628 0,661 +0,033 12	
ionosfera 0,882 0,888 +0,006 5	
íris 0,936 0,931 -0,005 3,5	
distúrbios hepáticos 0,661 0,668 +0,007 6	
câncer de pulmão 0,583 0,583 0,000 1,5	
linfografia 0,775 0,838 +0,063 14	
cogumelo 1.000 1.000 0.000 1.5	
tumor primário 0,940 0,962 +0,022 11	
reumatismo 0,619 0,666 +0,047 13	
votação 0,972 0,981 +0,009 8	
vinho 0,957 0,978 +0,021 10	

Tabela 2: Comparação da AUC para C4,5 com $m = 0$ e C4,5 com m ajustado para a AUC ideal.

as colunas à direita ilustram o cálculo e normalmente não seriam publicadas em um artigo real.

O terceiro problema é que o teste t é, tal como a média dos conjuntos de dados, afetado por valores atípicos que distorcem as estatísticas do teste e diminuir o poder do teste aumentando o erro padrão estimado.

3.1.3 TESTE DE POSTOS SINALIZADOS DE WILCOXON

O teste de postos sinalizados de Wilcoxon (Wilcoxon, 1945) é uma alternativa não paramétrica ao teste t pareado, que classifica as diferenças de desempenho de dois classificadores para cada conjunto de dados, ignorando os sinais, e compara as classificações para as diferenças positivas e negativas.

Seja d_i novamente a diferença entre as pontuações de desempenho dos dois classificadores no i -ésimo resultado de N conjuntos de dados. As diferenças são classificadas de acordo com seus valores absolutos; as classificações médias são atribuído em caso de empate. Seja R^+ a soma das classificações dos conjuntos de dados nos quais o segundo algoritmo superou o primeiro, e R^- a soma das classificações para o oposto. As classificações de $d_i = 0$ são divididas uniformemente entre as somas; se houver um número ímpar delas, uma é ignorada:

$$R^+ = \sum_{d_i > 0} \text{classificação}(d_i) + \frac{1}{2} \sum_{d_i = 0} \text{classificação}(d_i) \quad R^- = \sum_{d_i < 0} \text{classificação}(d_i) + \frac{1}{2} \sum_{d_i = 0} \text{classificação}(d_i).$$

Seja T a menor das somas, $T = \min(R^+, R^-)$. A maioria dos livros de estatística geral inclui uma tabela de valores críticos exatos para T para N até 25 (ou às vezes mais). Para um número maior de dados conjuntos, as estatísticas

$$z = \frac{T - \frac{1}{4}N(N+1)}{\sqrt{\frac{1}{24}N(N+1)(2N+1)}}$$

é distribuído aproximadamente normalmente. Com $\alpha = 0,05$, a hipótese nula pode ser rejeitada se z for menor que -1,96.

DEMSAR

Vamos ilustrar o procedimento com um exemplo. A Tabela 2 mostra a comparação da AUC para C4.5 com m (o número mínimo de exemplos em uma folha) definido como zero e C4.5 com m ajustado para a AUC ótima. Para esta última, a AUC foi calculada com validação cruzada interna de 5 vezes em exemplos de treinamento para $m \in \{0, 1, 2, 3, 5, 10, 15, 20, 50\}$. Os experimentos foram realizados em 14 conjuntos de dados do repositório UCI com atributo de classe binária. Utilizamos o código C4.5 original de Quinlan, equipado com uma interface que o integra ao sistema de aprendizado de máquina Orange (Demsar e Zupan, 2004), que nos forneceu os procedimentos de validação cruzada, classes para argumentos de ajuste e as funções de pontuação. Estamos tentando rejeitar a hipótese nula de que ambos os algoritmos têm desempenho igualmente bom.

Existem dois conjuntos de dados nos quais os classificadores tiveram o mesmo desempenho (câncer de pulmão e cogumelo); se houvesse um número ímpar deles, ignoraríamos um. As classificações são atribuídas da menor para a maior diferença absoluta, e as diferenças iguais (0,000, $\pm 0,005$) recebem classificações médias.

A soma das classificações para as diferenças positivas é $R^+ = 3,5 + 9 + 12 + 5 + 6 + 14 + 11 + 13 + 8 + 10 + 1,5 = 93$ e a soma das classificações para as diferenças negativas é igual a $R^- = 7 + 3,5 + 1,5 = 12$. De acordo com a tabela de valores críticos exatos para o teste de Wilcoxon, para um nível de confiança de $\alpha = 0,05$ e $N = 14$ conjuntos de dados, a diferença entre os classificadores é significativa se a menor das somas for igual ou menor que 21. Portanto, rejeitamos a hipótese nula.

O teste de postos sinalizados de Wilcoxon é mais sensato do que o teste t . Ele pressupõe a commensurabilidade das diferenças, mas apenas qualitativamente: diferenças maiores ainda contam mais, o que provavelmente é desejável, mas as magnitudes absolutas são ignoradas. Do ponto de vista estatístico, o teste é mais seguro, pois não pressupõe distribuições normais. Além disso, os valores discrepantes (desempenhos excepcionalmente bons/ruins em alguns conjuntos de dados) têm menos efeito no teste de Wilcoxon do que no teste t .

O teste de Wilcoxon assume diferenças contínuas d_i , portanto, eles não devem ser arredondados para, digamos, uma ou duas casas decimais, pois isso diminuiria o poder do teste devido ao alto número de empates.

Quando as premissas do teste t pareado são atendidas, o teste de postos sinalizados de Wilcoxon é menos poderoso do que o teste t pareado. Por outro lado, quando as premissas são violadas, o teste de Wilcoxon pode ser ainda mais poderoso do que o teste t .

3.1.4 CONTAGENS DE VITÓRIAS, DERROTAS E EMPATES: TESTE DE SINAL

Uma maneira popular de comparar o desempenho geral de classificadores é contar o número de conjuntos de dados nos quais um algoritmo é o vencedor geral. Quando vários algoritmos são comparados, as comparações em pares às vezes são organizadas em uma matriz.

Alguns autores também usam essas contagens em estatísticas inferenciais, com uma forma de teste binomial conhecido como teste do sinal (Sheskin, 2000; Salzberg, 1997). Se os dois algoritmos comparados forem, como assumido sob a hipótese nula, equivalentes, cada um deve vencer em aproximadamente $N/2$ de N conjuntos de dados. O número de vitórias é distribuído de acordo com a distribuição binomial; o número crítico de vitórias pode ser encontrado na Tabela 3. Para um número maior de conjuntos de dados, o número de vitórias está sob a hipótese nula distribuída de acordo com $N(N/2, \sqrt{N}/2)$, o que permite o uso do teste z : se o número de vitórias for pelo menos $N/2 + 1,96\sqrt{N}/2$ (ou, para uma regra prática rápida, $N/2 + \sqrt{N}$), o algoritmo é significativamente melhor com $p < 0,05$. Como os empates apoiam a hipótese nula, não devemos descontá-los, mas dividi-los igualmente entre os dois classificadores; se houver um número ímpar deles, ignoramos um novamente.

#conjuntos de dados	5	6	7	8	9	10	11	12	13	14	15	16	17	18	19	20	21	22	23	24	25	w0,05	5	6	7	7	8	9	9	10	10			
	11	12	12	13	13	14	15	15	16	17	18	18	w0,10	5	6	6	7	7	8	9	9	10	10	11	12	12	13	13	14	14	15	16	16	17

Tabela 3: Valores críticos para o teste de sinal bicaudal em $\hat{y} = 0,05$ e $\hat{y} = 0,10$. Um classificador é significativamente significativamente melhor que outro se tiver melhor desempenho em pelo menos $w\hat{y}$ conjuntos de dados.

No exemplo da Tabela 2, C4.5+m foi melhor em 11 dos 14 conjuntos de dados (contando também um dos dois conjuntos de dados em que os dois classificadores estavam empatados). De acordo com a Tabela 3, essa diferença é significativa com $p < 0,05$.

Este teste não pressupõe qualquer commensurabilidade de pontuações ou diferenças, nem assume distribuições normais e, portanto, é aplicável a quaisquer dados (desde que as observações, *ou seja*, os conjuntos de dados, sejam independentes). Por outro lado, é muito mais fraco do que o teste de postos sinalizados de Wilcoxon. De acordo com a Tabela 3, o teste de sinal não rejeitará a hipótese nula, a menos que um algoritmo quase sempre supere o outro.

Alguns autores preferem contabilizar apenas os ganhos e perdas significativos, sendo a significância determinada por meio de um teste estatístico para cada conjunto de dados, como, por exemplo, o $5 \times 2cv$ de Dietterich. O raciocínio por trás dessa prática é que "alguns ganhos e perdas são aleatórios e não devem ser contabilizados". Este seria um argumento válido se os testes estatísticos pudessem distinguir entre diferenças aleatórias e não aleatórias. No entanto, os testes estatísticos apenas medem a improbabilidade do resultado experimental obtido se a hipótese nula estiver correta, o que nem sequer corresponde à (im)probabilidade da hipótese nula.

Para fins de argumentação, suponha que comparamos dois algoritmos em mil conjuntos de dados diferentes. Em todos os casos, o algoritmo A foi melhor que o algoritmo B, mas a diferença nunca foi significativa. É verdade que, para cada caso específico, a diferença entre os dois algoritmos pode ser atribuída a um acaso, mas qual a probabilidade de um algoritmo ter tido sorte em todos os 1.000 dos 1.000 experimentos independentes?

Ao contrário da crença popular, contar apenas vitórias e derrotas significativas não torna os testes mais, mas sim menos confiáveis, pois traça um limite arbitrário de $p < 0,05$ entre o que conta e o que não conta.

3.2 Comparações de vários classificadores

Nenhum dos testes acima foi projetado para raciocinar sobre as médias de múltiplas variáveis aleatórias. Muitos autores de artigos sobre aprendizado de máquina, no entanto, os utilizam para esse propósito. Um exemplo comum desse procedimento questionável seria comparar sete algoritmos, realizando todos os 21 testes t pareados e relatando resultados como "o algoritmo A foi considerado significativamente melhor que B e C, e os algoritmos A e E foram significativamente melhores que D, enquanto não houve diferenças significativas entre os outros pares". Quando tantos testes são realizados, uma certa proporção das hipóteses nulas é rejeitada devido ao acaso, portanto, listá-las faz pouco sentido.

A questão dos testes de hipóteses múltiplas é um problema estatístico bem conhecido. O objetivo usual é controlar o *erro familiar*, a probabilidade de ocorrer pelo menos um erro Tipo 1 em qualquer uma das comparações. Na literatura sobre aprendizado de máquina, Salzberg (1997) menciona uma solução geral para o erro

DEMSAR

problema dos testes múltiplos, a correção de Bonferroni, e observa que ela costuma ser muito conservadora e fraca, pois supõe a independência das hipóteses.

A estatística oferece procedimentos especializados mais poderosos para testar a significância das diferenças entre múltiplas médias. Em nossa situação, os dois mais interessantes são a conhecida ANOVA e sua contraparte não paramétrica, o teste de Friedman. Este último, e especialmente seu correspondente teste post-hoc de Nemenyi, são menos conhecidos e a literatura sobre eles é menos abundante; por esse motivo, os apresentamos com mais detalhes.

3.2.1 Análise de variância

O método estatístico comum para testar as diferenças entre mais de duas médias amostrais relacionadas é a *ANOVA de medidas repetidas* (ou *ANOVA intrassujeitos*) (Fisher, 1959). As "amostras relacionadas" são, novamente, os desempenhos dos classificadores medidos nos mesmos conjuntos de dados, preferencialmente usando as mesmas divisões nos conjuntos de treinamento e teste. A hipótese nula testada é que todos os classificadores têm o mesmo desempenho e que as diferenças observadas são meramente aleatórias.

A ANOVA divide a variabilidade total em variabilidade entre os classificadores, variabilidade entre os conjuntos de dados e variabilidade residual (erro). Se a variabilidade entre os classificadores for significativamente maior que a variabilidade do erro, podemos rejeitar a hipótese nula e concluir que há *algumas* diferenças entre os classificadores. Nesse caso, podemos prosseguir com um teste post-hoc para descobrir quais classificadores realmente diferem. De muitos desses testes para ANOVA, os dois mais adequados para nossa situação são o teste de Tukey (Tukey, 1949) para comparar todos os classificadores entre si e o teste de Dunnett (Dunnett, 1980) para comparações de todos os classificadores com o controle (por exemplo, comparar o classificador base e algumas melhorias propostas, ou comparar o classificador recém-proposto com vários métodos existentes). Ambos os procedimentos calculam o erro padrão da diferença entre dois classificadores dividindo a variância residual pelo número de conjuntos de dados. Para realizar comparações pareadas entre os classificadores, as diferenças correspondentes nos desempenhos são divididas pelo erro padrão e comparadas com o valor crítico. Os dois procedimentos são, portanto, semelhantes a um teste t, exceto que os valores críticos tabulados por Tukey e Dunnett são maiores para garantir que haja no máximo 5% de chance de que uma das diferenças pareadas seja erroneamente considerada significativa.

Infelizmente, a ANOVA se baseia em suposições que são provavelmente violadas ao analisar o desempenho de algoritmos de aprendizado de máquina. Primeiro, a ANOVA assume que as amostras são extraídas de distribuições normais. Em geral, não há garantia de normalidade das distribuições de precisão de classificação em um conjunto de problemas. É verdade que, mesmo que as distribuições sejam anormais, este é um problema menor e muitos estatísticos não se oporiam ao uso da ANOVA, a menos que as distribuições fossem, por exemplo, claramente bimodais (Hamilton, 1990). A segunda e mais importante suposição da ANOVA de medidas repetidas é a esfericidade (uma propriedade semelhante à homogeneidade da variância na ANOVA usual, que requer que as variáveis aleatórias tenham variância igual). Devido à natureza dos algoritmos de aprendizado e dos conjuntos de dados, isso não pode ser considerado garantido. Violações dessas suposições têm um efeito ainda maior nos testes post-hoc. A ANOVA, portanto, não parece ser um teste abrangente adequado para os estudos típicos de aprendizado de máquina.

Não descreveremos a ANOVA e seus testes post-hoc com mais detalhes devido às nossas reservas sobre os testes paramétricos e, principalmente, porque esses testes são bem conhecidos e descritos na literatura estatística (Zar, 1998; Sheskin, 2000).

		ANOVA p		
		$< 0,01$ $0,01 \leq p < 0,05$ $0,05 \leq p < 1$		
Friedman	$p < 0,01$	16		0
teste	$0,01 \leq p < 0,05$	4	1	4
	$< p$	0	2	28

Tabela 4: Comparação de Friedman entre seu teste e a ANOVA de medidas repetidas em 56 problemas independentes (Friedman, 1940).

3.2.2 TESTE DE FRIEDMAN

O teste de Friedman (Friedman, 1937, 1940) é um equivalente não paramétrico da ANOVA de medidas repetidas. Ele classifica os algoritmos para cada conjunto de dados separadamente, com o algoritmo de melhor desempenho recebendo a classificação 1 e o segundo melhor, a classificação 2..., conforme mostrado na Tabela 6. Em caso de empate (como em íris, câncer de pulmão, cogumelo e tumor primário), são atribuídas classificações médias.

Seja a classificação do j -ésimo dos k algoritmos no i -ésimo dos N conjuntos de dados. O teste de Friedman Seja r_{ij} $i, j = 1, \dots, k$. Sob a hipótese nula, que afirma compara as classificações médias dos algoritmos, $R_j = \frac{1}{N} \sum_{i=1}^N r_{ij}$ que todos os algoritmos são equivalentes e, portanto, suas classificações R_j devem ser iguais, a estatística de Friedman

$$\chi_F^2 = \frac{12N}{k(k+1)} \sum_{j=1}^k R_j^2 - \frac{k(k+1)}{4}$$

é distribuído de acordo com χ^2 com $k-1$ graus de liberdade, quando N e k são suficientemente grandes (como regra geral, $N > 10$ e $k > 5$). Para um número menor de algoritmos e conjuntos de dados, valores críticos exatos foram calculados (Zar, 1998; Sheskin, 2000).

Iman e Davenport (1980) mostraram que o χ_F^2 de Friedman é uma estatística melhor e χ_F^2 é indesejavelmente conservador e derivado

$$= N(k-1) \frac{(\sum_{j=1}^k R_j^2 - \frac{(\sum_{j=1}^k R_j)^2}{k})}{\sum_{j=1}^k R_j^2 - \frac{(\sum_{j=1}^k R_j)^2}{k}}$$

distribuído de acordo com a distribuição F com $k-1$ e $(k-1)(N-1)$ graus de liberdade.

A tabela de valores críticos pode ser encontrada em qualquer livro de estatística.

Quanto às comparações entre dois classificadores, o teste de Friedman (não paramétrico) tem teoricamente menos poder do que a ANOVA (paramétrica) quando as premissas da ANOVA são atendidas, mas isso não precisa ser o caso quando elas não são atendidas. Friedman (1940) comparou experimentalmente a ANOVA e seu teste em 56 problemas independentes e mostrou que os dois métodos concordam em grande parte (Tabela 4). Quando um método encontra significância em $p < 0,01$, o outro mostra significância de pelo menos $p < 0,05$. Apenas em 2 casos a ANOVA encontrou significativo o que era insignificante para Friedman, enquanto o oposto ocorreu em 4 casos.

Se a hipótese nula for rejeitada, podemos prosseguir com um teste post-hoc. O teste de Nemenyi (Nemenyi, 1963) é semelhante ao teste de Tukey para ANOVA e é usado quando todos os classificadores são comparados entre si. O desempenho de dois classificadores é significativamente diferente se as classificações médias correspondentes diferirem em pelo menos a diferença crítica.

$$CD = q \sqrt{\frac{k(k+1)}{6N}}$$

DEMSAR

#classificadores	2	3	4	5	6	7	8	9
q0,05	1,960	2,343	2,569	2,728	2,850	2,949	3,031	3,102
q0,10	1,645	2,052	2,291	2,459	2,589	2,693	2,780	2,855

(a) Valores críticos para o teste de Nemenyi bicaudal

#classificadores	2	3	4	5	6	7	8	9	10
q0,05	1,960	2,241	2,394	2,498	2,576	2,638	2,690	2,724	2,773
q0,10	1,645	1,960	2,128	2,241	2,326	2,394	2,450	2,498	2,539

(b) Valores críticos para o teste de Bonferroni-Dunn bicaudal; o número de classificadores inclui o controle classificador.

Tabela 5: Valores críticos para testes post-hoc após o teste de Friedman

onde os valores críticos q_{γ} são baseados na estatística de intervalo estudantil dividida por $\sqrt{2}$ (Tabela 5(a)).

Quando todos os classificadores são comparados com um classificador de controle, podemos, em vez do teste de Nemenyi usar um dos procedimentos gerais para controlar o erro familiar em testes de hipóteses múltiplas, como a correção de Bonferroni ou procedimentos semelhantes. Embora esses métodos sejam geralmente conservadores e podem ter pouco poder, eles são neste caso específico mais poderosos do que o teste de Nemenyi, uma vez que este ajusta o valor crítico para fazer comparações $k(k-1)/2$ enquanto quando comparando com um controle fazemos apenas $k-1$ comparações.

As estatísticas de teste para comparar o i -ésimo e o j -ésimo classificador usando esses métodos são

$$z = \frac{(R_i - R_j) \sqrt{k(k+1)}}{\sqrt{6N}}$$

O valor z é usado para encontrar a probabilidade correspondente na tabela de distribuição normal, que é então comparado com um γ apropriado. Os testes diferem na maneira como ajustam o valor de γ para compensar comparações múltiplas.

O teste de Bonferroni-Dunn (Dunn, 1961) controla a taxa de erro familiar dividindo γ pelo número de comparações feitas ($k-1$, no nosso caso). A maneira alternativa de calcular o mesmo teste é para calcular o CD usando a mesma equação do teste de Nemenyi, mas usando os valores críticos para $\gamma/(k-1)$ (por conveniência, são apresentados na Tabela 5(b)). A comparação entre as tabelas para o teste de Nemenyi e Dunn mostra que o poder do teste post-hoc é muito maior quando todos os classificadores são comparados apenas com um classificador de controle e não entre si. Portanto, não devemos fazer comparações em pares quando, na verdade, apenas testamos se um método recém-proposto é melhor do que os existentes.

Para contrastar com o procedimento de Bonferroni-Dunn de etapa única, os procedimentos de aumento e redução testam sequencialmente as hipóteses ordenadas por sua significância. Denotamos o p ordenado valores por $p_1, p_2, \dots$, de modo que $p_1 \leq p_2 \leq \dots \leq p_k$. Os métodos mais simples são devidos a Holm (1979) e Hochberg (1988). Ambos comparam cada p_i com $\gamma/(k-i)$, mas diferem na ordem

dos testes.¹ O procedimento de redução gradual de Holm começa com o valor *de p* mais significativo. Se p_1 for menor que $\hat{y}/(k \hat{y} 1)$, a hipótese correspondente é rejeitada e podemos comparar p_2 com $\hat{y}/(k \hat{y} 2)$. Se a segunda hipótese for rejeitada, o teste prossegue com a terceira, e assim por diante. Assim que uma determinada hipótese nula não puder ser rejeitada, todas as hipóteses restantes também são mantidas.

O procedimento de Hochberg funciona na direção oposta, comparando o maior valor *de p* com $\hat{y}$, o segundo maior com $\hat{y}/2$ e assim por diante até encontrar uma hipótese que possa rejeitar. Todas as hipóteses com valores *de p* menores também são rejeitadas.

O procedimento de Hommel (Hommel, 1988) é mais complexo de calcular e compreender. Primeiro, precisamos encontrar o maior j para o qual $p_{(j)} \hat{y} j + k > k \hat{y} j$ para todo $k = 1..j$. Se tal j não existir, podemos rejeitar todas as hipóteses; caso contrário, rejeitamos todas para as quais $p_i \hat{y} \hat{y} / j$.

O procedimento de Holm é mais poderoso que o de Bonferroni-Dunn e não faz suposições adicionais sobre as hipóteses testadas. A única vantagem do teste de Bonferroni-Dunn parece ser sua facilidade de descrição e visualização, pois utiliza o mesmo CD para todas as comparações. Por sua vez, os métodos de Hochberg e Hommel rejeitam mais hipóteses que o de Holm, mas podem, em algumas circunstâncias, exceder o erro familiar prescrito, visto que se baseiam na conjectura de Simes, que ainda está sendo investigada. Foi relatado (Holland, 1991) que as diferenças entre os métodos aprimorados são, na prática, bastante pequenas; portanto, o método de Hommel, mais complexo, não oferece grande vantagem sobre o método de Holm simples.

Embora utilizemos aqui esses procedimentos apenas como testes post-hoc para o teste de Friedman, eles podem ser usados de forma geral para controlar o erro familiar quando múltiplas hipóteses de tipos possivelmente diversos são testadas. Existem outros métodos semelhantes, bem como alguns métodos que, em vez de controlar o erro familiar, controlam o número de hipóteses nulas falsamente rejeitadas (taxa de descoberta falsa, FDR). Estes últimos são menos adequados para a avaliação de algoritmos de aprendizado de máquina, pois exigem que o pesquisador decida qual é a taxa de descoberta falsa aceitável. Uma descrição formal e discussão mais completa de todos esses procedimentos foi escrita, por exemplo, por Shaffer (1995).

Às vezes, o teste de Friedman relata uma diferença significativa, mas o teste post-hoc não a detecta. Isso se deve ao menor poder deste último. Neste caso, não se pode tirar nenhuma outra conclusão além de que alguns algoritmos diferem. Em nossos experimentos, no entanto, isso ocorreu apenas em alguns casos em mil.

O procedimento é ilustrado pelos dados da Tabela 6, que compara quatro algoritmos: C4.5 com m fixo em 0 e cf (intervalo de confiança) em 0,25; C4.5 com m ajustado em validação cruzada interna de 5 vezes; C4.5 com cf ajustado da mesma forma; e, finalmente, C4.5, no qual ajustamos ambos os argumentos, testando todas as combinações de seus valores. O parâmetro m foi definido como 0, 1, 2, 3, 5, 10, 15, 20, 50 e cf como 0, 0,1, 0,25 e 0,5.

As classificações médias por si só fornecem uma comparação justa entre os algoritmos. Em média, C4.5+ m e C4.5+ m + cf ficaram em segundo lugar (com classificações de 2.000 e 1.964, respectivamente), e C4.5 e C4.5+ cf ficaram em terceiro (3.143 e 2.893). O teste de Friedman verifica se as classificações médias medidas são significativamente diferentes da classificação média $R_j = 2.5$ esperada sob a hipótese nula:

$$\hat{y}_F^2 = \frac{12 \cdot 14}{4 \cdot 5} (3,1432 + 2,0002 + 2,8932 + 1,9642) \hat{y} \frac{2 \cdot 4 \cdot 5}{4} = 9,28$$

$$FF = \frac{13 \cdot 9,28}{14 \cdot 3 \cdot 9,28} = 3,69.$$

1. Nas definições usuais destes procedimentos k denotaria o número de hipóteses, enquanto no nosso caso o número de hipóteses é $k \hat{y} 1$, daí as diferenças nas fórmulas.

DEMSAR

C4.5	C4.5+m C4.5+cf 0,768 (3)	C4,5+m+cf
adulto (amostra) 0,763 (4) câncer	0,771 (2) 0,591 (2) 0,590 (3)	0,798 (1)
de mama 0,599 (1) câncer de	0,971 (1) 0,968 (2) 0,661 (1)	0,569 (4)
mama Wisconsin 0,954 (4) cmc 0,628 (4)	0,654 (3) 0,888 (2) 0,886 (3)	0,967 (3)
ionosfera 0,882 (4)	0,931 (2,5) 0,916 (4) 0,668	0,657 (2)
íris 0,936 (1) distúrbios	(2) 0,609 (4) câncer de pulmão	0,898 (1)
hepáticos 0,661 (3)	0,583 (2,5) 0,583 (2,5) 0,563	0,931 (2,5)
	(4) linfografia 0,775 (4) 0,838	0,685 (1)
(3) 0,866 (2) cogumelo 1,000 (2,5) 1,000 (2,5) 1,000 (2,5) tumor		0,625 (1)
primário 0,940 (4) 0,962 (2,5) 0,965 (1) reum 0,619 (3) 0,666 (2)		0,875 (1)
0,614 (4) votação 0,972 (4) 0,981 (1) 0,975 (2) vinho 0,957 (3) 0,978		1,000 (2,5)
(1) 0,946 (4) classificação média 3,143 2,000 2,893		0,962 (2,5)
		0,669 (1)
		0,975 (3)
		0,970 (2)
		1.964

Tabela 6: Comparação da AUC entre C4.5 com $m = 0$ e C4.5 com parâmetros m e/ou cf ajustados para a AUC ideal. As classificações entre parênteses são usadas no cálculo da AUC de Friedman teste e normalmente não seria publicado em um artigo real.

Com quatro algoritmos e 14 conjuntos de dados, o FF é distribuído de acordo com a distribuição F com $4 \times 1 = 3$ e $(4 \times 1) \times (14 \times 1) = 39$ graus de liberdade. O valor crítico de $F(3,39)$ para $\alpha = 0,05$ é 2,85, então rejeitamos a hipótese nula.

Uma análise mais aprofundada depende do que pretendemos estudar. Se nenhum classificador for destacado, use o teste de Nemenyi para comparações pareadas. O valor crítico (Tabela 5(a)) é 2,569 e o

CD correspondente é 2,569 $\frac{4 \cdot 5}{6 \cdot 14} = 1,25$. Já que até mesmo a diferença entre o melhor e o pior

o algoritmo de execução já é menor do que isso, podemos concluir que o teste post-hoc não é poderoso o suficiente para detectar quaisquer diferenças significativas entre os algoritmos.

Em $p=0,10$, CD é 2,291 $\frac{4 \cdot 5}{6 \cdot 14} = 1,12$. Podemos identificar dois grupos de algoritmos: o desempenho do C4.5

puro é significativamente pior do que o de C4.5+m e C4.5+m+cf. Não podemos dizer

a qual grupo C4.5+cf pertence. Concluir que pertence a ambos seria um absurdo estatístico

já que um sujeito não pode vir de duas populações diferentes. A afirmação estatística correta seria seja que os dados experimentais não sejam suficientes para chegar a qualquer conclusão sobre C4.5+cf.

A outra hipótese possível feita antes da coleta dos dados poderia ser que é possível

melhorar o desempenho do C4.5 ajustando seus parâmetros. A maneira mais fácil de verificar isso é calcular

o CD com o teste de Bonferroni-Dunn. Na Tabela 5(b) encontramos que o valor crítico $q_{0,05}$ para 4

classificadores é 2,394, então CD é 2,394 $\frac{4 \cdot 5}{6 \cdot 14} = 1,16$. C4,5+m+cf tem desempenho significativamente melhor do que

C4.5 (**3,143** $\hat{y}$ **1,964** = 1,179 > 1,16) e C4.5+cf não (**3,143** $\hat{y}$ **2,893** = 0,250 < 1,16), enquanto

C4,5+m está logo abaixo da diferença crítica, mas próximo dela (3,143 $\hat{y}$ 2,000 = 1,143 $\hat{y}$ 1,16).

podemos concluir que os experimentos mostraram que o ajuste de m parece ajudar, embora não tenhamos detectado nenhuma melhoria significativa através da adaptação de cf .

Para os outros testes, temos que calcular e ordenar as estatísticas correspondentes e os valores de p .

erro padrão é $SE = \frac{4 \cdot 5}{6 \cdot 14} = 0,488$.

classificador	$z = (R0 - \bar{y}_R) / SE_p \sqrt{1/C4.5 + m + cf} (3,143\sqrt{1,964}) / 0,488$
1	$= 2,416 \ 0,016 \ 0,017 \ 2 \ C4.5 + m (3,143\sqrt{2,000}) / 0,488 = 2,342 \ 0,019 \ 0,025 \ C4.5 + cf$
2	$(3,143\sqrt{2,893}) / 0,488 = 0,512 \ 0,607 \ 0,050$
3	

O procedimento de Holm rejeita a primeira e, em seguida, a segunda hipótese, uma vez que os valores de p correspondentes são menores que os $\hat{\alpha}$ ajustados. A terceira hipótese não pode ser rejeitada; se houvesse mais, teríamos que mantê-las também.

O procedimento de Hochberg começa de baixo para cima. Incapaz de rejeitar a última hipótese, ele verifica a penúltima, rejeita-a e, junto com ela, todas as hipóteses com valores de p menores (a mais alta).

Por fim, o procedimento de Hommel descobre que $j = 3$ não satisfaz a condição em $k = 2$. O valor máximo de j é 2, e as duas primeiras hipóteses podem ser rejeitadas, pois seus valores de p estão abaixo de $\hat{\alpha}/2$.

Todos os procedimentos de redução e aumento de intensidade encontraram C4.5+cf+m e C4.5+m significativamente diferentes de C4.5, enquanto o teste de Bonferroni-Dunn encontrou C4.5 e C4.5+m muito semelhantes.

3.2.3 CONSIDERANDO MÚLTIPLAS REPETIÇÕES DE EXPERIMENTOS

Em nossos exemplos, utilizamos AUCs medidas e calculadas em média ao longo de repetições de episódios de treinamento/teste. Por exemplo, cada célula na Tabela 6 representa uma média de uma validação cruzada de cinco vezes.

Poderíamos também considerar a variância, ou mesmo os resultados de dobras individuais?

Existem variações da ANOVA e do teste de Friedman que podem considerar *múltiplas observações por célula*, desde que as observações sejam independentes (Zar, 1998). Este não é o caso aqui, uma vez que os dados de treinamento em múltiplas amostras aleatórias se sobrepõem. Não temos conhecimento de nenhum teste estatístico que possa levar isso em consideração.

3.2.4 APRESENTAÇÃO GRÁFICA DOS RESULTADOS

Quando múltiplos classificadores são comparados, os resultados dos testes post-hoc podem ser representados visualmente por meio de um diagrama simples. A Figura 1 mostra os resultados da análise dos dados da Tabela 6. A linha superior do diagrama é o eixo no qual plotamos as classificações médias dos métodos. O eixo é girado de forma que as classificações mais baixas (melhores) fiquem à direita, visto que percebemos os métodos do lado direito como melhores.

Ao comparar todos os algoritmos entre si, conectamos os grupos de algoritmos que não são significativamente diferentes (Figura 1(a)). Também mostramos a diferença crítica acima do gráfico.


Se os métodos forem comparados ao controle usando o teste de Bonferroni-Dunn, podemos marcar o intervalo de um CD à esquerda e à direita da classificação média do algoritmo de controle (Figura 1(b)).

Qualquer algoritmo com classificação fora dessa área é significativamente diferente do controle. Gráficos semelhantes para os outros testes post-hoc precisariam traçar um intervalo crítico ajustado diferente para cada classificador e especificar o procedimento usado para o teste e a ordem correspondente das comparações, o que poderia facilmente se tornar confuso.


Como outro exemplo, a Figura 2 representa graficamente a comparação das medidas de pontuação de recursos para o problema de predição de palavras-chave em cinco domínios formados a partir da hierarquia do Yahoo, estudada por Mladenic e Grobelnik (1999). A análise revela que o desempenho do ganho de informação é significativamente pior do que o peso da evidência, a entropia cruzada e a razão de chances, que parecem ter

formulários

DEMSAR



(a) Comparação de todos os classificadores entre si com o teste de Nemenyi. Grupos de classificadores que não são significativamente diferentes (em $p = 0,10$) estão conectados.



(b) Comparação de um classificador com os demais pelo teste de Bonferroni-Dunn. Todos os classificadores com classificação fora os intervalos marcados são significativamente diferentes ($p < 0,05$) do controle.

Figura 1: Visualização de testes post-hoc para dados da Tabela 6.




Figura 2: Comparação de recalls para várias medidas de seleção de recursos; análise dos resultados de o artigo de Mladenic e Grobelnik (1999).

desempenhos equivalentes. Os dados não são suficientes para concluir se a informação mútua Txt tem o mesmo desempenho que o ganho de informação ou a frequência do termo e, da mesma forma, se a frequência do termo é equivalente ao Mutual information Txt ou aos três melhores métodos.

4. Comparação empírica de testes

Observamos experimentalmente duas propriedades dos testes descritos: sua replicabilidade e a probabilidade de rejeição da hipótese nula. Realizando os experimentos para responder a perguntas como "qual teste estatístico tem maior probabilidade de dar o resultado correto" ou "qual teste tem o menor Tipo 1/Tipo 2 "taxa de erro" seria um exercício inútil, uma vez que os testes inferenciais propostos supõem diferentes tipos

de commensurabilidade e, assim, comparar os classificadores sob diferentes aspectos. A "resposta correta", rejeição ou não rejeição da hipótese nula, não é, portanto, bem determinada e está, em certo sentido, relacionada à escolha do teste.

4.1 Configuração Experimental

Examinamos o comportamento dos testes estudados por meio de experimentos nos quais comparamos repetidamente os algoritmos de aprendizagem em conjuntos de dez conjuntos de dados sorteados aleatoriamente e registramos os valores de p retornados pelos testes.

4.1.1 CONJUNTOS DE DADOS E ALGORITMOS DE APRENDIZAGEM

Baseamos nossos experimentos em vários algoritmos de aprendizagem comuns e suas variações: C4.5, C4.5 com m e C4.5 com cf ajustado para precisão ideal, outro algoritmo de aprendizagem de árvore implementado em Orange (com recursos semelhantes ao C4.5 original), aprendiz bayesiano ingênuo que modela probabilidades contínuas usando LOESS (Cleveland, 1979), aprendiz bayesiano ingênuo com atributos contínuos discretizados usando discretização de Fayyad-Irani (Fayyad e Irani, 1993) e kNN ($k=10$, pesos vizinhos ajustados com o kernel gaussiano).

Compilamos uma amostra de quarenta conjuntos de dados do mundo real,² do repositório de aprendizado de máquina da UCI (Blake e Merz, 1998); utilizamos os conjuntos de dados com classes discretas e evitamos conjuntos de dados artificiais, como os problemas de Monk. Como nenhum classificador é ótimo para todos os conjuntos de dados possíveis, simulamos experimentos nos quais um pesquisador deseja demonstrar vantagens específicas de um algoritmo específico e, assim, seleciona um compêndio correspondente de conjuntos de dados. Fizemos isso medindo previamente a precisão de classificação dos classificadores em todos os conjuntos de dados, utilizando validação cruzada décupla. Ao comparar dois classificadores, amostras de dez conjuntos de dados foram selecionadas aleatoriamente para que a probabilidade do conjunto de dados i ser escolhido fosse proporcional a $1/(1+e^{-k d_i})$, onde d_i é a diferença (positiva ou negativa) nas precisões de classificação naquele conjunto de dados e k é o viés através do qual podemos regular as diferenças entre os classificadores.³ Enquanto em $k = 0$ a seleção do conjunto de dados é aleatória com a distribuição uniforme, com valores mais altos de k temos mais probabilidade de selecionar os conjuntos que favorecem um método de aprendizagem particular. Note que escolher os conjuntos de dados sabendo seu sucesso (como estimado antecipadamente) é apenas uma simulação, enquanto o pesquisador selecionaria os conjuntos de dados de acordo com outros critérios. Usar o procedimento descrito em avaliações práticas de algoritmos seria considerado trapaça.

Decidimos evitar classificadores e conjuntos de dados "artificiais" construídos especificamente para testar os testes estatísticos, como os usados, por exemplo, por Dietterich (1998). Em tais procedimentos experimentais, algumas suposições precisam ser feitas sobre os conjuntos de dados do mundo real e os algoritmos de aprendizagem, e os dados e algoritmos artificiais são construídos de forma a imitar a suposta situação do mundo real de forma controlável. No nosso caso, construiríamos dois ou mais classificadores com uma probabilidade de falha prescrita sobre um conjunto de conjuntos de dados (possivelmente imaginários) para que pudéssemos:

2. Os conjuntos de dados usados são: adulto, balança, bandas, câncer de mama (Haberman), câncer de mama (LJU), câncer de mama (Wisc), avaliação de carro, escolha de método contraceptivo, triagem de crédito, dermatologia, Ecoli, identificação de vidro, Hayes-Roth, hepatite, habitação, importações-85, ionosfera, íris, distúrbios hepáticos, câncer de pulmão, linfografia, cogumelos, diabetes dos índios Pima, pós-operatório, tumor primário, promotores, reumatismo, servo, pouso do ônibus espacial, soja, spambase, Spect, Spectf, avaliação de assistente de ensino, jogo da velha, Titanic, votação, forma de onda, reconhecimento de vinho, levedura.

3. A função utilizada é a função logística. Ela foi escolhida por sua forma conveniente; não afirmamos que tal relação realmente ocorre na prática ao selecionar os conjuntos de dados para experimentos.

conhecendo a hipótese correta, observe as taxas de erro do Tipo 1 e 2 dos testes estatísticos propostos.

Infelizmente, não sabemos quais devem ser nossas suposições sobre o mundo real. Até que ponto as precisões de classificação (ou outras medidas de sucesso) são incomensuráveis? Quão (a)normal é sua distribuição? Quão homogênea é a variância? Além disso, se fizermos certas suposições, a teoria estatística já é capaz de dizer os resultados dos experimentos que estamos configurando. Como os testes estatísticos que usamos são teoricamente bem compreendidos, não precisamos testar os testes, mas sim a conformidade dos dados do mundo real com suas suposições. Em outras palavras, sabemos, a partir da teoria, que o teste t em uma pequena amostra (ou seja, em um pequeno número de conjuntos de dados) requer a distribuição normal; portanto, ao construir um ambiente artificial que produzirá distribuições não normais, podemos fazer o teste t falhar. A verdadeira questão, no entanto, é se as distribuições *do mundo real* são normais o suficiente para que o teste t funcione.

Não podemos testar as suposições diretamente? Como já mencionado na descrição do teste t, testes como o teste de normalidade de Kolmogorov-Smirnov não são confiáveis em amostras pequenas, onde é muito improvável que detectem anormalidades. E mesmo que tivéssemos testes adequados à disposição, eles calculariam apenas o grau de (a)normalidade da distribuição, a não homogeneidade da variância, *etc.*, e não a adequação da amostra para o teste t.

Nossa decisão de usar algoritmos de aprendizagem e conjuntos de dados do mundo real sem modificações nos impede de definir artificialmente as diferenças entre eles, fazendo com que classifiquem incorretamente uma certa proporção de exemplos intencionalmente. Isso é, no entanto, compensado por nosso método de seleção dos conjuntos de dados: podemos regular as diferenças entre os algoritmos de aprendizagem afetando a seleção do conjunto de dados por meio da regulação do viés k . Dessa forma, realizamos os experimentos em conjuntos de dados e algoritmos do mundo real e, ainda assim, observamos o desempenho das estatísticas em vários graus de diferença entre os classificadores.

4.1.2 MEDIDAS DE POTÊNCIA E REPLICABILIDADE

Formalmente, o poder de um teste estatístico é definido como a probabilidade de o teste rejeitar (corretamente) a hipótese nula falsa. Como nosso critério do que é realmente falso está relacionado à seleção do teste (que deve se basear no tipo de diferenças entre os classificadores que queremos medir), podemos apenas observar a probabilidade de rejeição da hipótese nula, que, no entanto, está relacionada ao poder.

Fazemos isso de duas maneiras. Primeiro, definimos o nível de significância em 5% e observamos em quantos experimentos, em mil, um teste específico rejeita a hipótese nula. A desvantagem disso é que ele observa apenas o comportamento das estatísticas em torno de $p = 0,05$ (que é provavelmente o que nos interessa), mas pode perder uma visão mais ampla. Portanto, também observamos os valores médios *de* p como outra medida do "poder" do teste: quanto menores os valores, maior a probabilidade de um teste rejeitar a hipótese nula em um determinado nível de confiança.

As duas medidas para avaliar o poder dos testes levam a duas medidas relacionadas de replicabilidade. Bouckaert (2004) propôs uma definição que pode ser usada em conjunto com a contagem das rejeições da hipótese nula. Ele definiu a replicabilidade como a probabilidade de que dois experimentos com o mesmo par de algoritmos produzam os mesmos resultados, ou seja, que ambos os experimentos aceitem ou rejeitem a hipótese nula, e concebeu o estimador ótimo não enviesado dessa probabilidade.

$$R(e) = \frac{1}{n} \sum_{i=1}^n \frac{I(e_i = e_j)}{n(n-1)/2}$$

onde e_i é o resultado do i -ésimo experimento de n (e_i é 1 se a hipótese nula for aceita, 0 se não for) e I é a função indicadora, que é 1 se seu argumento for verdadeiro e 0 caso contrário. Bouckaert também descreve uma maneira mais simples de calcular $R(e)$: se a hipótese foi aceita em p e rejeitada em q experimentos de n , $R(e)$ é igual a $(p(p-1) + q(q-1))/n(n-1)$. O valor mínimo de R , 0,5, ocorre quando $p = q = n/2$, e o máximo, 1,0, quando p ou q é zero.

A desvantagem dessa medida é que um teste estatístico apresentará baixa replicabilidade quando a diferença entre os classificadores for marginalmente significativa. Ao comparar dois testes com poder diferente, aquele com resultados mais próximos do $\bar{y}$ escolhido geralmente será considerado menos confiável.

Quando o poder é estimado pela média dos valores de p , a replicabilidade é naturalmente definida por meio de sua variância. A variância de p está entre 0 e 0,25; esta última ocorre quando metade de p é igual a zero e a outra metade é igual a um.⁴ Para permitir comparações com o $R(e)$ de Bouckaert, definimos a replicabilidade em relação à variância de p como

$$R(p) = \frac{1}{2} \cdot \text{var}(p) = \frac{1}{2} \frac{\sum_{i=1}^n (p_i - \bar{p})^2}{n-1}.$$

Um problema com essa medida de replicabilidade, quando usada em nosso procedimento experimental, é que, quando o viés k aumenta, a variabilidade da seleção do conjunto de dados diminui, assim como a variância de p . O tamanho do efeito depende do número de conjuntos de dados. A julgar pelos resultados dos experimentos, nossa coleção de quarenta conjuntos de dados é grande o suficiente para manter a variabilidade praticamente inalterada para os valores de k utilizados (veja o gráfico à esquerda na Figura 4.c; se a variabilidade das seleções diminuísse, a variância de p não poderia permanecer constante).

As definições descritas de replicabilidade estão relacionadas. Como $I(e_i = e_j)$ é igual a $\frac{1}{2}(e_i - e_j)^2$,² nós podemos reformular $R(e)$ como

$$R(e) = \frac{1}{2} \frac{\sum_{i=1}^n \sum_{j=1}^n (e_i - e_j)^2}{n(n-1)} = \frac{1}{2} \frac{\sum_{i=1}^n (e_i - \bar{e})^2}{n-1} = \frac{1}{2} \frac{\sum_{i=1}^n (e_i - \bar{e})^2}{n-1}.$$

A partir daqui é fácil verificar que

$$R(e) = \frac{1}{2} \frac{\sum_{i=1}^n (e_i - \bar{e})^2}{n-1}.$$

O fato de a fórmula de Bouckaert ser o estimador não enviesado ótimo para $R(e)$ está relacionado ao fato de $\frac{1}{2} \sum_{i=1}^n (e_i - \bar{e})^2 / (n-1)$ ser o estimador não enviesado ótimo da variância da população.

4.2 Comparações de dois classificadores

Testamos quatro estatísticas para comparações de dois classificadores: o teste t pareado para diferenças absolutas e relativas, o teste de Wilcoxon e o teste do sinal. Os experimentos foram realizados em 1.000 seleções aleatórias de dez conjuntos de dados, conforme descrito acima.

Os gráficos do lado esquerdo da Figura 3 mostram os valores médios de p retornados pelos testes em função do viés k ao comparar C4.5-cf, classificador bayesiano ingênuo e kNN (observe que a escala está invertida, de modo que a curva sobe quando o poder do teste aumenta). Os gráficos do lado direito mostram o número de experimentos em que a hipótese foi rejeitada em

4. Como estimamos a variância populacional a partir da variância amostral, a variância estimada será maior em $0,25/(n-1)$. Com qualquer número razoável de experimentos, a diferença é, no entanto, insignificante.

DEMSAR

$\hat{y} = 5\%$. Para demonstrar a relação entre o poder (como o medimos) e a medida de replicabilidade de Bouckaert, adicionamos o eixo direito que mostra $R(e)$ correspondente ao número de hipóteses rejeitadas.

Observe que em $k = 0$ o número de experimentos nos quais a hipótese nula é rejeitada não é 50%. Configurações mais baixas de k não implicam que ambos os algoritmos comparados devam ter desempenho aproximadamente igual, mas apenas que não influenciaremos (artificialmente) a seleção dos conjuntos de dados para favorecer um deles. Portanto, em $k = 0$, os testes refletem o número de rejeições da hipótese nula em uma seleção completamente aleatória de conjuntos de dados de nossa coleção.

Ambas as variações do teste t apresentam resultados semelhantes, com o teste de diferenças relativas sendo ligeiramente, porém consistentemente, mais fraco. O teste de postos sinalizados de Wilcoxon apresenta valores de p muito mais baixos e tem maior probabilidade de rejeitar a hipótese nula do que os testes t em quase todos os casos. O teste do sinal é, como se sabe pela teoria, muito mais fraco do que os outros testes.

As duas medidas de replicabilidade apresentam resultados bastante diferentes. Julgado por $R(p)$ (gráficos no lado esquerdo da Figura 4), o teste de Wilcoxon apresenta a menor variação dos valores de p . Em contraste, o $R(e)$ de Bouckaert (lado direito da Figura 4) mostra o teste de Wilcoxon como o menos confiável. Entretanto, o formato das curvas nesses gráficos e os eixos retos na Figura 3 mostram claramente que o teste é menos confiável (de acordo com $R(e)$) quando os valores de p estão mais próximos de 0,05, então o teste de Wilcoxon parece não confiável devido ao seu maior poder, mantendo-o mais próximo de $p=0,05$ do que os outros testes.

A Tabela 7 mostra comparações de todos os sete classificadores com k definido como 15. Os números abaixo da diagonal mostram os valores médios de p e a replicabilidade relacionada $R(p)$, e os números acima da diagonal representam o número de experimentos nos quais a hipótese nula foi rejeitada em $\hat{y} = 5\%$ e o $R(e)$ relacionado. A tabela mostra novamente que o teste de Wilcoxon quase sempre retorna valores de p menores do que outros testes e rejeita a hipótese nula com mais frequência. Medido por $R(p)$, o teste de Wilcoxon também apresenta a maior replicabilidade. $R(e)$, por outro lado, novamente prefere outros testes com valores de p mais distantes do ponto crítico de 0,05.

De modo geral, sabe-se que testes paramétricos têm maior probabilidade de rejeitar a hipótese nula do que os não paramétricos, a menos que suas premissas sejam violadas. Nossos resultados sugerem que isso de fato ocorre em estudos de aprendizado de máquina que comparam algoritmos entre conjuntos de dados. Portanto, recomendamos o uso do teste de Wilcoxon, a menos que as premissas do teste t sejam atendidas, seja porque temos muitos conjuntos de dados ou porque temos razões para acreditar que a medida de desempenho entre os conjuntos de dados é distribuída normalmente. O teste do sinal, como terceira alternativa, é muito fraco para ser útil em geral.

Valores baixos de $R(e)$ sugerem que devemos garantir a confiabilidade dos resultados (especialmente quando as diferenças entre os classificadores são marginalmente significativas) executando os experimentos em tantos conjuntos de dados apropriados quanto possível.

4.3 Comparações de vários classificadores

Para a comparação de múltiplos classificadores, amostras de conjuntos de dados foram selecionadas com probabilidades calculadas a partir das diferenças na precisão de classificação do classificador C4.5 e do classificador bayesiano ingênuo com discretização de Fayyad-Irani. Esses dois classificadores foram escolhidos sem nenhuma razão específica; verificamos que a escolha não tem efeito prático nos resultados.

Os resultados são mostrados na Figura 5. Quando os algoritmos são mais semelhantes (em valores menores de k), o teste não paramétrico de Friedman novamente parece mais forte do que o paramétrico, ANOVA. Em valores maiores

COMPARAÇÕES ESTATÍSTICAS DE CLASSIFICADORES EM VÁRIOS CONJUNTOS DE DADOS






Figura 3: Poder dos testes estatísticos para comparação de dois classificadores. Esquerda: valores de p em função do viés (k). Direita: número de vezes que a hipótese foi rejeitada (eixo esquerdo) e o R de Bouckaert (eixo direito).


DEMSAR



(a) C45-cf vs. Bayes ingênuo



(b) C45-cf vs. kNN



(c) Bayes ingênuo vs. kNN

Figura 4: Replicabilidade dos testes para comparação de dois classificadores: $R(p)$ baseado em variância (esquerda) e $R(e)$ de Bouckaert (direita).

COMPARAÇÕES ESTATÍSTICAS DE CLASSIFICADORES EM VÁRIOS CONJUNTOS DE DADOS

	c45	c45-m	c45-cf	disco	bayes	bayes	knn
c45		154/.74	709/.59	818/.70	178/.71	0/1.00	151/.74
c45-m	.16/.96		307/.57	909/.83	300/.58	0/1,00	376/.53
c45-cf	.05/.99	.10/.98	árvore	758/.63	335/.55	0/1,00	167/.72
	.04/.98	.02/1.00	.05/.98 bayes	.15/.96	679/.56	162/.73	592/.52
	.12/.97	disco-bayes	.41/.92	.11/.97	.05/.99	0/1,00	2/1,00
.20/.95 knn	.16/.96	.10/.98		.28/.92	.18/.94	.20/.97	.14/.97
				.06/.99	.35/.94	0,01/1,00	

(a) Teste t pareado

	c45	c45-m	c45-cf	árvore	disco	de bayes-bayes	knn
c45		75/.86	592/.52	809/.69	181/.70	0/1.00	184/.70
c45-m	.17/.96		238/.64	848/.74	314/.57	0/1,00	438/.51
c45-cf	.06/.99	.11/.98		729/.60	361/.54	0/1,00	216/.66
árvore	.04/.99	.03/1.00	.06/.98 bayes		662/.55	79/.85	584/.51
	.16/.95	.12/.97	disc-bayes	.11/.97	.05/.99	0/1,00	1/1,00
.36/.94 .20/.96 knn	.14/.96	.09/.98		.27/.94	.19/.95	.24/.98	.13/.97
				.06/.99	.35/.95	0,01/1,00	

(b) Teste t pareado em diferenças relativas

	c45	c45-m	c45-cf	521/.50	árvore	disco	bayesiano	81/.85	knn
c45		884/.79	897/.82	662/.55	774/.65	983/.97	710/.59	351/.54	618/.53
c45-m	.08/.98	c45-		854/.75	804/.68			172/.71	750/.62
cf	.03/1.00	.04/.99							720/.60
árvore	.02/1.00	.01/1.00	.03/1.00			915/.84	521/.50		920/.85
bayes	.06/.99	disc-	0,05/0,99	.04/.99	.02/1.00		94/.83		102/.82
bayes	.22/.96	knn	.07/.98	.11/.98	.16/.97	.08/.98	.18/.97		999/1,00
				.04/.99	.05/.99	.02/1.00	.22/.96	.00/1,00	

(c) Teste de postos sinalizados de Wilcoxon

	c45	c45-m	c45-cf	árvore	disco	de bayes-bayes	knn
c45		157/.74	323/.56	653/.55	171/.72	48/.91	110/.80
c45-m	.21/.90		205/.67	863/.76	299/.58	156/.74	256/.62
c45-cf	.10/.98	.16/.93		513/.50	423/.51	95/.83	229/.65
árvore	.05/.99	.02/1.00	.09/.97 bayes		460/.50	210/.67	486/.50
	.19/.89	.13/.94	disc-bayes	.08/.97	.08/.97	0/1,00	1/1,00
.29/.89 .18/.93 knn	.25/.85	.14/.93		.25/.89	.18/.93	.15/.93	.52/.78
				.07/.97	.45/.86	0,01/1,00	

(d) Teste de sinal

Tabela 7: Testes para comparações de dois classificadores: valores p médios e $R(p)$ (abaixo da diagonal), e o número de rejeições de hipóteses nulas e $R(e)$ (acima da diagonal).




Figura 5: Comparação entre ANOVA e teste de Friedman

diferenças entre os algoritmos (k em torno de 10, em nossa configuração experimental), a ANOVA alcança e os dois testes dão resultados semelhantes.

A replicabilidade do teste de Friedman é maior que a da ANOVA quando medida por $R(p)$ e, devido ao poder similar dos testes, comparável quando medida por $R(e)$. No geral, a replicabilidade parece um pouco menor que a replicabilidade dos testes para comparações de dois classificadores.

Portanto, como o senso comum sugere, ao comparar vários classificadores, é ainda mais importante conduzir os testes no maior número possível de conjuntos de dados.

A Figura 6 mostra a comparação entre o teste paramétrico de Tukey e o teste não paramétrico de Nemenyi. Contamos o número de vezes que eles rejeitaram a equivalência de C4.5-cf e o classificador Bayesiano ingênuo e a equivalência de C4.5-cf e kNN (a comparação entre o classificador Bayesiano ingênuo e kNN, que foi incluída em testes anteriores, foi menos interessante, pois a hipótese nula foi muito raramente rejeitada). Os dois gráficos à esquerda representam experimentos nos quais a seleção foi baseada nas diferenças entre os dois algoritmos comparados no gráfico, enquanto para os dois gráficos à direita usamos as diferenças entre o C4.5-cf e a média dos outros seis classificadores testados. Em todos os casos, comparamos todos os sete algoritmos, mas apresentamos apenas o número de rejeições para o par no gráfico. O teste não paramétrico novamente rejeita com mais frequência a hipótese nula do que o paramétrico.

Não mostramos os valores de p e as replicabilidades correspondentes, pois eles nem sempre podem ser calculados ou comparados em todos os procedimentos devido às diferentes ordens de testes.

A Figura 7 compara testes post hoc para comparações com um classificador de controle, utilizando as mesmas duas maneiras de selecionar conjuntos de dados da Figura 6. Quando as diferenças são grandes, o poder de todos os testes é comparável, enquanto quando são menores, o número de rejeições para o teste paramétrico parece ficar para trás (observamos esse mesmo padrão em outras combinações de algoritmos). A ordem dos testes não paramétricos é a esperada pela teoria, embora seja interessante notar que os testes de Holm e Hochberg apresentam resultados praticamente iguais.

COMPARAÇÕES ESTATÍSTICAS DE CLASSIFICADORES EM VÁRIOS CONJUNTOS DE DADOS




Figura 6: Poder dos testes estatísticos para comparação de múltiplos classificadores. O viés é definido pela diferença de desempenho dos dois classificadores no gráfico (esquerda) ou entre o C4.5-cf e todos os outros classificadores (direita). A escala da esquerda em cada gráfico indica o número de vezes que a hipótese foi rejeitada e a escala da direita indica o $R(e)$ correspondente.

Esses experimentos parecem, mais uma vez, favorecer os testes não paramétricos em relação aos paramétricos, embora nem sempre de forma tão convincente quanto no caso de comparações entre dois classificadores. Devido às vantagens teóricas e práticas do teste de Friedman (facilidade de cálculo e interpretação, capacidade de apresentar o desempenho geral dos classificadores na forma de classificações em vez de médias duvidosas), o teste de Friedman deve ser preferível à ANOVA. Os testes post-hoc não paramétricos correspondentes fornecem resultados semelhantes, portanto, cabe ao pesquisador decidir se o teste de Hommel, ligeiramente mais poderoso, compensa a complexidade de seu cálculo em comparação com o teste de Holm, muito mais simples.

DEMSAR




Figura 7: Poder dos testes estatísticos para comparação de múltiplos classificadores com um controle. O viés é definido pela diferença de desempenho dos dois classificadores no gráfico (à esquerda) ou entre o C4.5-cf e a média de todos os outros classificadores (à direita). A escala à esquerda em cada gráfico indica o número de vezes que a hipótese foi rejeitada e a escala à direita indica o R de Bouckaert correspondente.

5. Conclusão

Nossa análise dos artigos das últimas Conferências Internacionais sobre Aprendizado de Máquina mostrou que muitos autores acreditam que os algoritmos que propõem devem ser comparados em um conjunto de problemas e que os resultados podem ser usados para tirar conclusões gerais. No entanto, não existe um padrão-ouro para fazer tais comparações, e os testes realizados frequentemente têm fundamentos estatísticos duvidosos e levam a conclusões injustificadas e não verificadas.

Enquanto as comparações que utilizam um único conjunto de dados são prejudicadas pelas estimativas de variância tendenciosas devido às dependências entre as amostras de exemplos extraídos do conjunto de dados, nas comparações sobre múltiplos conjuntos de dados a variância provém das diferenças entre os conjuntos de dados, que são geralmente

Independente. Nossa configuração está, portanto, livre do erro Tipo 1 elevado, comum em procedimentos de teste de conjuntos de dados individuais. Os problemas com os testes de conjuntos de dados múltiplos são bastante diferentes, até mesmo complementares em certo sentido: as medições de diferentes conjuntos de dados são geralmente incomensuráveis, e a normalidade de suas distribuições e a homogeneidade da variância são, na melhor das hipóteses, questionáveis.

Analisamos teórica e empiricamente três famílias de testes estatísticos que podem ser usados para comparar dois ou mais classificadores em múltiplos conjuntos de dados: testes paramétricos (teste t pareado e ANOVA), testes não paramétricos (teste de Wilcoxon e teste de Friedman) e o teste não paramétrico que não assume commensurabilidade dos resultados (teste do sinal). Na parte teórica, discutimos especificamente as possíveis violações das premissas dos testes por dados típicos de aprendizado de máquina. Com base nas propriedades estatísticas bem conhecidas dos testes e em nosso conhecimento dos dados de aprendizado de máquina, concluímos que os testes não paramétricos devem ser preferidos aos paramétricos.

Observamos o comportamento das estatísticas propostas em diversos classificadores e conjuntos de dados do mundo real. Variamos as diferenças entre os classificadores, enviesando a seleção dos conjuntos de dados, e medimos a probabilidade de rejeição da hipótese nula e a replicabilidade do teste. De fato, constatamos que os testes não paramétricos têm maior probabilidade de rejeitar a hipótese nula, o que sugere a presença de valores discrepantes ou violações de pressupostos dos testes paramétricos e confirma nossas dúvidas teóricas sobre eles. A análise empírica também mostra que a replicabilidade dos testes pode ser um problema, portanto, os experimentos reais devem ser conduzidos no maior número possível de conjuntos de dados.

No estudo empírico, não fornecemos nenhuma análise das taxas de erro Tipo 1/Tipo 2. A principal razão para isso é que o resultado correto — rejeição ou não rejeição da hipótese nula — não está bem definido e depende do tipo de diferença entre os algoritmos que pretendemos medir. Além disso, conduzir os experimentos nos quais conhecemos as hipóteses verdadeiras exigiria conjuntos de dados artificiais e classificadores com as probabilidades e distribuições de erros prescritas. Para isso, precisaríamos fazer algumas suposições sobre as distribuições do mundo real; essas suposições são, no entanto, exatamente o que estávamos testando em primeiro lugar.

No geral, os testes não paramétricos, a saber, os testes de Wilcoxon e Friedman, são adequados para nossos problemas. Eles são *apropriados*, pois assumem alguma, mas limitada, commensurabilidade. São *mais seguros do que os testes paramétricos*, pois não assumem distribuições normais ou homogeneidade de variância. Como tal, podem ser aplicados a precisões de classificação, taxas de erro ou qualquer outra medida para avaliação de classificadores, incluindo tamanhos de modelos e tempos de computação. Os resultados empíricos sugerem que eles também são *mais robustos do que os outros testes estudados*. Este último é particularmente verdadeiro ao comparar um par de classificadores.

Propusemos uma representação visual da análise post-hoc quando múltiplos classificadores são comparados. Os diagramas de CD são "econômicos em termos de espaço" e, portanto, adequados quando o tamanho do artigo é um problema, mas apresentam a ordem dos algoritmos, a magnitude das diferenças entre eles (em termos de classificação) e a significância das diferenças observadas com muito mais clareza do que seria possível em texto ou em forma puramente numérica.

Existe uma opinião alternativa entre os estatísticos de que testes de significância não devem ser realizados, visto que são frequentemente mal utilizados, seja por má interpretação ou por dar muita ênfase aos seus resultados (Cohen, 1994; Schmidt, 1996; Harlow e Mulaik, 1997). Nossa posição é que os testes estatísticos fornecem certa garantia quanto à validade e à não aleatoriedade dos resultados publicados. Para que isso seja verdade, eles devem ser realizados corretamente e as conclusões resultantes devem ser tiradas com cautela. Por outro lado, os testes estatísticos não devem ser o fator decisivo a favor ou contra a publicação do trabalho. Outros méritos do algoritmo proposto que estão além do alcance de

DEMSAR

testes estatísticos também devem ser considerados e possivelmente até favorecidos em detrimento de melhorias puras no poder preditivo.

Agradecimentos

Gostaria de agradecer aos meus colegas do Laboratório de Inteligência Artificial e do Laboratório de Modelagem Cognitiva da Faculdade de Ciência da Computação e Informação em Liubliana, Eslovênia, especialmente Blaz̃y Zupan e Aleks Jakulin por seus comentários e sugestões inestimáveis.

Referências

- E. Alpaydın. Teste combinado 5×2 F para comparação de algoritmos de aprendizagem de classificação supervisionada. *Computação Neural*, 11:1885–1892, 1999.
- JR Beck e EK Schultz. O uso de curvas ROC na avaliação de desempenho em testes. *Arch Pathol Laboratório Med*, 110:13–20, 1986.
- R. Bellazzi e B. Zupan. Análise inteligente de dados em medicina e farmacologia: uma declaração de posicionamento. Em *Notas do Workshop IDAMAP na 13ª Conferência Europeia sobre Inteligência Artificial, ECAI-98*, Brighton, Reino Unido, 1998.
- Y. Bengio e Y. Grandvalet. Nenhum estimador imparcial da variância da validação cruzada k-fold. *Revista de pesquisa em aprendizado de máquina*, 5:1089–1105, 2004.
- CL Blake e CJ Merz. Repositório UCI de bancos de dados de aprendizado de máquina, 1998. URL <http://www.ics.uci.edu/ymlearn/MLRepository.html>.
- RR Bouckaert. Escolhendo entre dois algoritmos de aprendizagem baseados em testes calibrados. Em T. Fawcett e N. Mishra, editores, *Aprendizado de Máquina, Anais da Vigésima Conferência Internacional (ICML 2003), 21 a 24 de agosto de 2003, Washington, DC, EUA*. AAAI Press, 2003.
- RR Bouckaert. Estimando a replicabilidade de experimentos de aprendizado de classificadores. Em C Brodley, editor, *Aprendizado de Máquina, Anais da Vigésima Primeira Conferência Internacional (ICML 2004)*. Imprensa AAAI, 2004.
- RR Bouckaert e E. Frank. Avaliando a replicabilidade de testes de significância para comparar algoritmos de aprendizagem. Em D. Honghua, R. Srikant e C. Zhang, editores, *Advances in Knowledge Discovery and Data Mining, 8ª Conferência Pacífico-Ásia, PAKDD 2004, Sydney, Austrália, 26 a 28 de maio de 2004, Anais*. Springer, 2004.
- PB Brazdil e C. Soares. Uma comparação de métodos de ranqueamento para seleção de algoritmos de classificação. Em *Anais da 11ª Conferência Europeia sobre Aprendizado de Máquina*. Springer Verlag, 2000.
- W. Cleveland. Regressão ponderada localmente robusta e diagramas de dispersão suavizados. *Journal of the American Statistical Association*, 74:329–336, 1979.
- J. Cohen. A Terra é redonda ($p < 0,05$). *Psicólogo Americano*, 49:997 1003, 1994.

- J. Demsar e B. Zupan. *Orange: Do Aprendizado de Máquina Experimental à Mineração de Dados Interativa, Um White Paper*. Faculdade de Ciência da Computação e Informação, Liubliana, Eslovênia, 2004.
- TG Dietterich. Testes estatísticos aproximados para comparar a aprendizagem supervisionada de classificação algoritmos. *Computação Neural*, 10:1895–1924, 1998.
- O.J. Dunn. Comparações múltiplas entre médias. *Journal of the American Statistical Association*, 56:52–64, 1961.
- CW Dunnett. Um procedimento de comparação múltipla para comparar vários tratamentos com um controle. *Revista da Associação Estatística Americana*, 50:1096–1121, 1980.
- UM Fayyad e KB Irani. Discretização multi-intervalo de atributos de valor contínuo para aprendizagem de classificação. Em *Anais da 13ª Conferência Internacional Conjunta sobre Inteligência Artificial*, páginas 1022–1029, Chambery, França, 1993. Morgan-Kaufmann.
- RA Fisher. *Métodos estatísticos e inferência científica (2ª edição)*. Hafner Publishing Co., Nova York Iorque, 1959.
- M. Friedman. O uso de classificações para evitar a suposição de normalidade implícita na análise de variância. *Revista da Associação Estatística Americana*, 32:675–701, 1937.
- M. Friedman. Uma comparação de testes alternativos de significância para o problema de classificações m. *Anais de Estatística Matemática*, 11:86–92, 1940.
- LC Hamilton. *Análise Moderna de Dados: Um Primeiro Curso em Estatística Aplicada*. Wadsworth, Belmont, Califórnia, 1990.
- LL Harlow e SA Mulaik, editores. *E se não houvesse testes de significância?* Lawrence Erlbaum Associates, julho de 1997.
- Y. Hochberg. Um procedimento de Bonferroni mais preciso para múltiplos testes de significância. *Biometrika*, 75: 800–803, 1988.
- B. Holland. Sobre a aplicação de três procedimentos de Bonferroni modificados a comparações múltiplas pareadas em delineamentos balanceados de medidas repetidas. *Computational Statistics Quarterly*, 6:219–231, 1991.
- S. Holm. Um procedimento simples de teste múltiplo de rejeição sequencial. *Revista Escandinava de Estatística*, 6:65–70, 1979.
- G. Hommel. Um procedimento de teste múltiplo de rejeição em estágios baseado em um teste de Bonferroni modificado. *Biometrika*, 75:383–386, 1988.
- DA Hull. *Recuperação de Informação Utilizando Classificação Estatística*. Tese de doutorado, Universidade Stanford, Novembro de 1994.
- RL Iman e JM Davenport. Aproximações da região crítica da estatística de Friedman. *Comunicações em Estatística*, páginas 571–595, 1980.

DEMSAR

- P. Langley. Elaboração de artigos sobre aprendizado de máquina. Em *Proc. da Décima Sétima Conferência Internacional sobre Aprendizado de Máquina (ICML-2000)*, 2000.
- D. Mladenic e M. Grobelnik. Seleção de características para distribuição de classes desbalanceada e bayesianos ingênuos. Em I. Bratko e S. Dzeroski, editores, *Machine Learning, Anais da Décima Sexta Conferência Internacional (ICML 1999)*, 27 a 30 de junho de 2002, Bled, Eslovênia, páginas 258–267. Morgan Kaufmann, 1999.
- C. Nadeau e Y. Bengio. Inferência para o erro de generalização. *Avanços em Informação Neural Sistemas de processamento*, 12:239–281, 2000.
- PB Nemenyi. *Comparações múltiplas sem distribuição*. Tese de doutorado, Universidade de Princeton, 1963.
- J. Pizarro, E. Guerrero e PL Galindo. Procedimentos de comparação múltipla aplicados à seleção de modelos. *Neurocomputing*, 48:155–173, 2002.
- F. Provost, T. Fawcett e R. Kohavi. O caso contra a estimativa de precisão para comparar algoritmos de indução. Em J. Shavlik, editor, *Anais da Décima Quinta Conferência Internacional sobre Aprendizado de máquina (ICML-1998)*, páginas 445–453, São Francisco, CA, 1998. Morgan Kaufmann Editoras.
- JR Quinlan. Ensacando, impulsionando e c4.5. Em *Proc. Décima Terceira Conferência Nacional sobre Artificial Inteligência*, páginas 725–730, Portland, OR, 1996. AAAI Press.
- SL Salzberg. Sobre a comparação de classificadores: armadilhas a evitar e uma abordagem recomendada. *Dados Mineração e descoberta de conhecimento*, 1:317–328, 1997.
- FL Schmidt. Teste de significância estatística e conhecimento cumulativo em psicologia. *Psicólogo-Métodos clínicos*, 1:115–129, 1996.
- H. Schutze, DA Hull e JO Pedersen. Uma comparação de classificadores e representações de documentos para o problema de roteamento. Em EA Fox, P. Ingwersen e R. Fidel, editores, *SIGIR'95, Anais da 18ª Conferência Internacional Anual ACM SIGIR sobre Pesquisa e Desenvolvimento em Recuperação de Informação*, páginas 229–237. ACM Press, 1995.
- JP Shaffer. Teste de hipóteses múltiplas. *Annual Review of Psychology*, 46:561–584, 1995.
- DJ Sheskin. *Manual de procedimentos estatísticos paramétricos e não paramétricos*. Chapman & Hall/CRC, 2000.
- JW Tukey. Comparando médias individuais na análise de variância. *Biometria*, 5:99–114, 1949.
- EG Vazquez, AY Escolano e JP Junquera PG Ria n.º Procedimentos de comparação múltipla de medidas repetidas aplicados à seleção de modelos em redes neurais. Em *Proc. da 6ª Conferência Internacional Sobre redes neurais artificiais e naturais (IWANN 2001)*, páginas 88–95, 2001.
- GI Webb. Multiboosting: Uma técnica para combinar boosting e wagging. *Aprendizado de Máquina*, 40:159–197, 2000.
- F. Wilcoxon. Comparações individuais por métodos de classificação. *Biometria*, 1:80–83, 1945.
- JH Zar. *Análise Bioestatística (4ª edição)*. Prentice Hall, Englewood Cliffs, Nova Jersey, 1998.